



**UNIVERSIDAD
DE GRANADA**

Desarrollo de un sistema RAG para recomendación basada en contenido

**SISTEMAS DE RECUPERACIÓN DE INFORMACIÓN Y DE
RECOMENDACIÓN**

Nombre: Teresa Córdoba Lillo

Correo: teresacordoba@correo.ugr.es

**MÁSTER UNIVERSITARIO EN CIENCIA DE DATOS E INGENIERÍA DE
COMPUTADORES**

Curso 2025-2026

Índice general

1.	Introducción	1
2.	Conjunto de datos	1
3.	Módulo I: Procesado de ítems	2
3.1.	Gestión de valores faltantes	2
3.2.	Transformación de variables	3
3.3.	Construcción del documento unificado	3
4.	Módulo II: Generación de <i>embeddings</i> e indexación	3
4.1.	Generación de <i>embeddings</i>	3
4.2.	Normalización e indexación con FAISS	3
5.	Módulo III: Construcción de perfiles de usuario y recuperación	4
5.1.	Selección de usuarios	4
5.2.	Estrategia de representación del perfil	4
5.3.	Recuperación con FAISS	4
6.	Módulos IV y V: Aumentación, generación y filtro de alucinaciones	4
6.1.	Elección del LLM	4
6.2.	Construcción del prompt	5
6.3.	Filtro de alucinaciones	5
7.	Módulo VI: Evaluación	5
7.1.	Análisis del re-ranking	5
7.2.	Valoración de las recomendaciones	6
8.	Conclusiones	6

1. Introducción

Un sistema RAG (*Retrieval-Augmented Generation*) es una arquitectura híbrida que combina un sistema de recuperación de información con un modelo de lenguaje de gran escala (LLM). Ante una consulta, el sistema recupera primero los fragmentos más relevantes de una base de conocimiento externa y los usa como contexto adicional para que el LLM genere una respuesta más precisa e informada.

Aplicado a la recomendación basada en contenido, este enfoque presenta ventajas frente al uso de un LLM estándar: reduce las alucinaciones al basar la generación de respuestas estrictamente en los datos del catálogo, permite trabajar con colecciones grandes y actualizadas sin reentrenar el modelo y produce recomendaciones explicables con justificaciones fundamentadas en el contenido de los ítems.

El objetivo de esta práctica es implementar y evaluar un SRC basado en RAG, integrando recuperación semántica vectorial con un LLM para generar recomendaciones personalizadas y justificadas para distintos perfiles de usuario.

2. Conjunto de datos

El conjunto de datos elegido es el **Anime Dataset 2023**, obtenido de la plataforma Kaggle. Se trata de una colección con información de casi 25.000 animes distintos. Este conjunto de datos resulta adecuado para esta práctica ya que dispone de descripciones textuales detalladas (sinopsis) para cada ítem. Además, cuenta con datos de interacciones de usuarios (valoraciones) que permiten construir perfiles reales.

En esta práctica se han usado dos archivos. El primero, `anime-dataset-2023.csv`, es el catálogo de ítems con información descriptiva de 24.905 obras. El segundo, `users-score-2023.csv`, recoge más de 24 millones de valoraciones explícitas (en una escala del 1 al 10) emitidas por 270.033 usuarios sobre 16.500 obras distintas.

En concreto, el archivo principal, `anime-dataset-2023.csv`, está compuesto por las siguientes columnas:

- **anime_id**: Identificador único para cada ítem.
- **Name**: Nombre de la obra en su idioma original.
- **English name**: Nombre oficial para su distribución internacional.
- **Other name**: Nombre o título nativo adicional (puede estar en japonés, chino o coreano).
- **Score**: Calificación media agregada del ítem.
- **Genres**: Lista de géneros asociados a la obra, separados por comas.
- **Synopsis**: Resumen de la trama (campo fundamental para la vectorización en el sistema RAG).
- **Type**: Formato de emisión (ej. serie de TV, película, OVA, ONA).
- **Episodes**: Número total de episodios que componen la obra.
- **Aired**: Fechas de inicio y fin de la emisión.
- **Premiered**: Temporada y año en que se estrenó (ej. *spring 2023*).
- **Status**: Estado actual de emisión (ej. finalizado, en emisión, próximo).
- **Producers**: Empresas de producción responsables de la obra.

- **Licensors:** Entidades que poseen las licencias de distribución (ej. plataformas de *streaming*).
- **Studios:** Estudios de animación encargados de la producción.
- **Source:** Material original en el que se basa (ej. manga, novela ligera, original).
- **Duration:** Duración aproximada por episodio.
- **Rating:** Clasificación por edades recomendada.
- **Rank:** Posición en el listado histórico general basada en su puntuación.
- **Popularity:** Posición basada en el volumen general de interacciones.
- **Favorites:** Frecuencia con la que el ítem ha sido marcado como favorito por los usuarios.
- **Scored By:** Número total de usuarios que han aportado una calificación.
- **Members:** Número de usuarios que incluyen la obra en sus listas personales en la plataforma.
- **Image URL:** Enlace a la imagen o póster promocional.

Por otro lado, el archivo `users-score-2023.csv` contiene las siguientes columnas:

- **user_id:** Identificador único del usuario.
- **Username:** Nombre de la cuenta del usuario en la plataforma.
- **anime_id:** Identificador de la obra valorada (clave foránea respecto al catálogo).
- **Anime Title:** Título de la obra.
- **rating:** Puntuación otorgada por el usuario al ítem (escala 1-10).

3. Módulo I: Procesado de ítems

El procesado de ítems comprende tres etapas: la gestión de valores faltantes, la transformación de variables y la construcción del documento unificado que servirá como entrada al modelo de *embeddings*.

3.1. Gestión de valores faltantes

El dataset presenta valores faltantes codificados como cadenas del tipo UNKNOWN, [null] o Not available, que fueron sustituidos por valores nulos reales (NaN) para poder gestionarlos de forma estándar.

El campo más crítico es **Synopsis**, ya que constituye la principal fuente de contenido semántico. Por ello y porque el total de filas con valor nulo en este campo no representa un porcentaje demasiado elevado con respecto al total, se optó por eliminar las filas que no tenían valor para esta columna reduciendo el catálogo de 24.905 a 20.370 ítems, un volumen más que suficiente para el sistema. Para el resto de campos con valores ausentes se optó por una imputación simple: el título en inglés se rellenó con el nombre original (**Name**), y las variables categóricas restantes (**Genres**, **Type**, **Studios**, **Source** y **Rating**) recibieron una etiqueta genérica indicando que el dato es desconocido (*genre unknown*, *type unknown*, etc.), evitando así reducir más el tamaño del catálogo.

3.2. Transformación de variables

Con el objetivo de enriquecer la representación semántica de cada ítem, se aplicaron dos transformaciones adicionales antes de construir el documento.

En primer lugar, el campo **Episodes** fue convertido de valor numérico a una categoría textual. Dado que el modelo de *embeddings* opera sobre texto, un número exacto de episodios aporta poco contexto semántico de forma aislada. Agrupar los valores en rangos descriptivos (*single episode / movie / special*, *short series*, *medium series*, *long series* y *very long series*) permite al modelo capturar la dimensión del formato de la obra.

En segundo lugar, se extrajo el año de emisión del campo **Aired** (la variable **Premiered** tenía muchos más valores faltantes) y siguiendo la misma lógica que con **Episodes** se creó una variable categórica (**Era**) que agrupe las obras por décadas: *classic anime*, *90s anime*, *2000s anime*, etc.

Finalmente, todas las columnas textuales fueron normalizadas eliminando espacios redundantes y convirtiendo el texto a minúsculas.

3.3. Construcción del documento unificado

Cada ítem del catálogo fue representado como un único documento de texto resultante de concatenar los siguientes campos: **English name**, **Genres**, **Type**, **Episodes**, **Era**, **Source**, **Studios**, **Rating** y **Synopsis**.

Se seleccionaron exclusivamente estos campos porque capturan la identidad, temática, formato y contexto de producción de la obra. Por otro lado, se han descartado las métricas numéricas y de interacción comunitaria (como popularidad, favoritos o puntuaciones) para garantizar un enfoque puramente basado en contenido, evitando así introducir sesgos o ruido.

La sinopsis fue colocada al final del documento de forma intencionada. El modelo utilizado para generar los *embeddings* (**all-MiniLM-L6-v2**) tiene una ventana de contexto de 256 *tokens*, y el análisis de la distribución de longitudes confirmó que el 98,5% de los documentos no supera ese límite. En los casos en que se produce truncamiento, el modelo podrá procesar todos los metadatos clave y el principio de la sinopsis, que esperablemente es suficiente para capturar la esencia de la obra.

4. Módulo II: Generación de *embeddings* e indexación

4.1. Generación de *embeddings*

Para transformar los documentos en vectores densos se utilizó el modelo **all-MiniLM-L6-v2**, disponible en la biblioteca **sentence-transformers** de Python. Se trata de un modelo ligero que genera vectores de 384 dimensiones y puede ejecutarse en CPU, lo que lo hace adecuado para el volumen del catálogo (20.370 ítems). El proceso de codificación se realizó en lotes de 64 documentos, obteniendo una matriz de *embeddings* de dimensiones 20.370×384 .

4.2. Normalización e indexación con FAISS

Los vectores fueron indexados mediante FAISS (*Facebook AI Similarity Search*) para realizar búsquedas semánticas eficientes. Antes de indexarlos, se aplicó una normalización L2 a cada vector, de modo que todos quedan con norma unitaria. Gracias a esta normalización, el producto escalar entre dos vectores es equivalente a su similitud coseno, lo que permite usar el índice **IndexFlatIP** (*Inner Product*) de FAISS como medida de similitud coseno de forma directa y eficiente.

5. Módulo III: Construcción de perfiles de usuario y recuperación

5.1. Selección de usuarios

Para evaluar el sistema con perfiles variados y bien definidos, se seleccionó un usuario representativo por cada uno de los siguientes géneros: Adventure, Action, Romance, Fantasy, Sci-Fi, Sports y Suspense. Como filtro inicial, se descartaron los usuarios con menos de 12 valoraciones en total, con el fin de asegurar que los perfiles construidos tuvieran suficiente información. El criterio de selección fue la proporción de valoraciones positivas (puntuación ≥ 8) en el género objetivo respecto al total de valoraciones positivas del usuario. De este modo se garantiza que el perfil construido refleja un gusto predominante por dicho género. Los 7 usuarios seleccionados presentaron una proporción del 100 % en su género correspondiente, lo que indica perfiles muy especializados.

5.2. Estrategia de representación del perfil

El guión propone construir el perfil de usuario concatenando los documentos de los ítems consumidos. Sin embargo, esta estrategia presenta un al estar usando `all-MiniLM-L6-v2`: su ventana de contexto de 256 *tokens* hace que la concatenación de varios documentos la supere ampliamente, por lo que el modelo solo procesaría el contenido del primer ítem o dos, ignorando el resto y sesgando la representación del perfil.

Para resolverlo, se optó por representar cada perfil como la **media ponderada por *rating* de los *embeddings* individuales** de los ítems consumidos por el usuario con puntuación mayor a 8, y se limitó el resultado a las 15 mejor valorados. Para cada usuario, el vector de perfil se calculó como:

$$\vec{p} = \frac{\sum_{i=1}^n r_i \cdot \vec{e}_i}{\sum_{i=1}^n r_i} \quad (1)$$

donde $\vec{e}_i$ es el *embedding* del ítem i y r_i su valoración. Este enfoque presenta varias ventajas: cada ítem contribuye con su representación completa sin pérdida de información por truncamiento, los ítems mejor valorados tienen mayor peso en el perfil, y reutiliza los *embeddings* ya calculados en la sesión anterior, siendo computacionalmente eficiente.

5.3. Recuperación con FAISS

Con los vectores de perfil construidos, se procedió a la fase de recuperación. La matriz de perfiles fue normalizada con L2 y se lanzó una búsqueda con FAISS para obtener los candidatos más similares a cada perfil. Se recuperaron inicialmente 30 candidatos por usuario, de los cuales se filtraron los ítems que ya formaban parte del perfil del propio usuario, conservando finalmente los 20 más similares.

6. Módulos IV y V: Aumentación, generación y filtro de alucinaciones

6.1. Elección del LLM

Para la fase de generación se utilizó la API de Google Gemini con el modelo `gemini-2.5-flash-lite`, accesible a través de Google AI Studio. Este modelo tiene una ventana de contexto de 1 millón de *tokens*, más que suficiente para incluir en el prompt el perfil del usuario y varios candidatos recuperados. Por otro lado, configuró con una temperatura de 0,2 para favorecer respuestas coherentes y reproducibles, y un máximo de 1000 *tokens* de salida.

6.2. Construcción del prompt

Para cada usuario se construyó un prompt aumentado con la siguiente estructura:

1. **Rol:** se indica al modelo que actúa como sistema de recomendación de anime y que debe responder únicamente en JSON válido considerando solo los candidatos proporcionados.
2. **Perfil del usuario:** se incluyen los documentos de los 5 animes mejor valorados por el usuario, concatenados como texto.
3. **Candidatos recuperados:** se presenta la lista de los 15 ítems más similares obtenidos por FAISS, cada uno con su documento completo.
4. **Instrucciones:** se solicita al modelo que realice un re-ranking de los 3 mejores ítems, justifique cada recomendación con detalles específicos de los metadatos, ignore los candidatos irrelevantes y no invente ítems ajenos a la lista.
5. **Formato de salida:** se especifica un esquema JSON estricto con los campos **ranking**, **título** y **razonamiento**.

6.3. Filtro de alucinaciones

Una vez obtenida la respuesta del LLM en formato JSON, se comprobó que cada título devuelto estuviera presente en la lista de candidatos de entrada, normalizando ambos a minúsculas para evitar falsos positivos por diferencias de capitalización. Las recomendaciones que no superaron esta verificación fueron descartadas.

En la evaluación realizada sobre los 7 usuarios, el modelo generó un total de 21 recomendaciones, de las cuales 1 correspondió a un título no presente en la lista de candidatos, lo que representa una tasa de alucinación del 4,8 %. Esta recomendación fue eliminada automáticamente por el filtro, garantizando que la salida final del sistema contiene únicamente ítems reales del catálogo.

7. Módulo VI: Evaluación

7.1. Análisis del re-ranking

Para evaluar el impacto del LLM sobre el ranking inicial de FAISS, se comparó la posición asignada por el LLM a cada ítem recomendado con su posición original en el ranking de recuperación. La Tabla 1 resume los resultados por usuario.

Usuario	Género	Rank LLM	Rank FAISS	Cambio	Título
360537	Adventure	1	2	+1	naruto shippuden the movie 2: bonds
		2	5	+3	boruto: naruto the movie
		3	6	+3	naruto shippuden the movie 6: road to ninja
104074	Action	1	1	+0	hunter x hunter
		2	5	+3	shakugan no shana: season i
		3	7	+4	dororo
1286221	Romance	1	6	+5	rosario + vampire
		3	1	-2	kokoro connect
338673	Fantasy	1	2	+1	fullmetal alchemist: reflections
		2	1	-1	fullmetal alchemist: brotherhood ova collection
		3	3	+0	fullmetal alchemist: premium ova collection
537333	Sci-Fi	1	2	+1	trigun
		2	5	+3	outlaw star
		3	3	+0	cowboy bebop: the movie
1099623	Sports	1	1	+0	captain tsubasa (2018)
		2	9	+7	inazuma eleven: ares
		3	5	+2	akakichi no eleven
1226789	Suspense	1	2	+1	chãos;head
		2	7	+5	the garden of sinners chapter 1: overlooking view
		3	1	-2	occultic;nine

Cuadro 1: Comparación entre el ranking de FAISS y el ranking final del LLM.

El LLM modificó el orden propuesto por FAISS en 16 de los 20 ítems evaluados (80 %), con un desplazamiento medio de 2,20 posiciones y un máximo de 7 puestos (usuario 1099623, género Sports). Esto indica que el LLM no se limita a validar el ranking de similitud vectorial, sino que reordena activamente los candidatos en función del contexto semántico del perfil, priorizando en ocasiones ítems que FAISS había situado en posiciones intermedias.

7.2. Valoración de las recomendaciones

En términos generales, la calidad de las recomendaciones es satisfactoria. El sistema muestra coherencia temática: los usuarios con perfiles muy especializados (Sports, Fantasy) reciben recomendaciones claramente alineadas con su género dominante y, en varios casos, directamente relacionadas con las franquicias que conforman su perfil. Las justificaciones generadas por el LLM son precisas y hacen referencia explícita a metadatos concretos como el género, el estudio, la era o la fuente, lo que aporta explicabilidad real al sistema.

No obstante, se observa una limitación notable en perfiles concentrados en pocas obras muy populares: el sistema tiende a recomendar secuelas, OVAs o películas de las mismas franquicias en lugar de explorar títulos distintos. Esto es especialmente visible en los usuarios de Fantasy y Adventure, cuyas recomendaciones giran casi en exclusiva en torno a los universos de *Fullmetal Alchemist* y *Naruto* respectivamente. Esta falta de diversidad es una consecuencia directa del enfoque puramente basado en contenido: los *embeddings* de obras de la misma franquicia son muy similares entre sí, dominando el ranking de recuperación de FAISS y dejando poco margen al LLM para introducir variedad.

8. Conclusiones

En esta práctica se ha implementado un sistema de recomendación basado en contenido mediante una arquitectura RAG completa, integrando recuperación semántica vectorial con un LLM generativo. El sistema es capaz de producir recomendaciones personalizadas y justificadas para distintos perfiles de usuario, cumpliendo los objetivos planteados.

Los resultados obtenidos muestran que la combinación de FAISS y *all-MiniLM-L6-v2* ofrece una recuperación semántica sólida, y que el LLM añade valor real al proceso al reordenar activamente los

candidatos en el 80 % de los casos, con un desplazamiento medio de 2,20 posiciones. Las justificaciones generadas son coherentes y específicas, lo que mejora la explicabilidad del sistema respecto a un SRC clásico.

Las recomendaciones generadas presentan una calidad general buena: son temáticamente coherentes con los perfiles de usuario, las justificaciones hacen referencia a metadatos concretos de los ítems y la tasa de alucinaciones fue baja (4,8 %), siendo el único caso detectado filtrado automáticamente. La principal debilidad observada es la de diversidad en las recomendaciones: el sistema tiende a recomendar contenido de las mismas franquicias, lo que limita la serendipia del sistema, aunque esta es una consecuencia inherente de los enfoques basados en contenido.

